



AGENTE X

Validación de la Solución en Producción
**Plataforma SaaS multi-tenant de Inteligencia de
Negocios Conversacional**

Plan de Exposición



BLOQUE	SLIDES	TIEMPO
Recap EA1 — Contexto y problema	1 – 3	3 min
Diseño y planificación	4 – 9	5 min
Arquitectura y stack tecnológico	10 – 12	4 min
Despliegue en la nube	13 – 14	4 min
DEMO EN VIVO de la app desplegada	15	8 min
Evidencia de funcionamiento	16 – 17	3 min
Integraciones y cierre	18 – 20	3 min

Punto de Partida · Recap EA1

Contexto y problema

Los directivos de PyMEs pierden horas semanales cruzando datos entre ERPs, planillas y reportes PDF para obtener respuestas simples.
La información estratégica está secuestrada detrás de interfaces técnicas.

Mercado objetivo

Usuario 1: Dueño / Gerente de PyME con inventario, ventas y operaciones logísticas.
Usuario 2: Vendedor o coordinador comercial que necesita datos del cliente en tiempo real.

Objetivo general

Desarrollar una plataforma SaaS multi-tenant de Agentes de IA especializados que permita a PyMEs consultar sus datos operativos en lenguaje natural, eliminando la dependencia de intermediarios técnicos.

Objetivos específicos

1. Arquitectura multi-tenant con aislamiento por empresa
2. Motores especializados conectados a endpoints ERP
3. Protocolo anti-alucinación jerárquico
4. Panel de administración B2B por roles diferenciados
5. Despliegue cloud con tres servicios independientes

Situación Inicial del Cliente (AS-IS)

Proceso actual:

- 1. Directivo formula una pregunta de negocio crítica
- 2. Accede manualmente al ERP para datos de inventario
- 3. Descarga métricas del CRM o pasarela de pagos
- 4. Busca documentos PDF con contexto adicional
- 5. Cruza toda la información en Excel manualmente
- 6. Redacta un reporte para tomar la decisión





Figura 2: Diagrama de flujo AS-IS — ver Anexos

Planificación del Proyecto

4 Sprints · 12 Semanas · Metodología ágil híbrida Scrum + Kanban

 Sprint	 Hito principal	 Período
Sprint 1	Diseño e implementación del esquema relacional en Supabase, sistema de autenticación JWT con roles diferenciados y configuración del entorno de desarrollo con Node.js y Express	27 abr 2026
Sprint 2	Motor de búsqueda léxica de inventario (erp_search) operativo, integración del microservicio Python con FastAPI y DeepSeek, sistema prompt jerárquico anti-alucinación e interfaz de chat conversacional en React	6 may 2026
Sprint 3	Motor analítico, motor de ventas con identificación semántica de clientes, motor de logística, formulario de aprovisionamiento B2B con mapeo dinámico de campos ERP y primer despliegue en producción (Render y Vercel)	14 may 2026
Sprint 4	Implementación de seguridad completa, panel de administración con vistas diferenciadas por rol, documentación Swagger/OpenAPI y logs estructurados con Pino	22 may 2026




Carta Gantt completa — Figuras 3.1 a 3.4 en Anexos

Servicios Cloud Utilizados




Área y Tecnología	Plataforma y Plan	Funcionalidad
Frontend — React + Vite	Vercel · PaaS · Hobby Gratis	Deploy automático desde GitHub, hosting web y CDN global
Backend — Node.js 20 + Express	Render · PaaS · Free Web Service	API principal del ERP
Microservicio IA — Python 3.11 + FastAPI	Render · PaaS · Free Web Service	Procesamiento semántico e integración IA
Base de Datos — PostgreSQL	Supabase · DBaaS · Free Tier	Persistencia de datos, relaciones ERP y backups automáticos
API DeepSeek — deepseek-chat	DeepSeek · SaaS · Pay per use	Generación de respuestas IA mediante consumo de tokens



Conceptualización · Solución TO-BE

⚠ Problema	✅ Solución
Atención manual lenta	Agentes IA con respuestas inmediatas
Falta de contexto operativo	Integración ERP en tiempo real
Procesos complejos	Chat en lenguaje natural
Dependencia técnica	Panel autogestionable por roles
Módulo	📌 Resumen
Orquestación Inteligente	Enrutamiento automático entre 4 motores especializados
Control Anti-Alucinación	Validación jerárquica basada en datos reales del ERP
Seguridad Multicapa	JWT, rate limiting, tokens internos y aislamiento por empresa
Gestión por Roles	Roles SUPER_ADMIN, ADMIN y USER con permisos diferenciados
Persistencia y Auditoría	Historial conversacional, métricas y trazabilidad completa
Acceso Multi-Dispositivo	Plataforma web responsiva disponible 24/7 desde navegador



Alcance, Supuestos y Restricciones

 Funcionalidades Incluidas
Autenticación JWT multi-tenant
Chat conversacional con 4 motores
Protocolo anti-alucinación
Aprovisionamiento B2B desde web
Panel de administración por roles
Historial de conversaciones
API REST documentada con Swagger
Infraestructura cloud en producción

Funcionalidades Excluidas

Motor RAG para documentos PDF (*BD preparada*)

Aplicación móvil nativa iOS/Android

Pasarela de pagos

Conexión SQL directa a ERPs

Supuestos

ERP con endpoints REST JSON

Disponibilidad de API DeepSeek

ADMIN conoce URLs del ERP

Render

Restricciones

12 semanas de desarrollo


1 desarrollador

Servicios en free tier

Cold start en Render (~30 seg)

Metodología de Desarrollo y Gestión

 Metodología / Roles	 Descripción
 Scrum híbrido + Kanban	Permite iterar y pivotar decisiones arquitecturales sin afectar funcionalidades implementadas
 Product Owner	Priorización y gestión del backlog
 Scrum Master	Gestión de bloqueos técnicos y seguimiento
 Desarrollador Full-Stack	Desarrollo frontend, backend y microservicios
 DevOps	Configuración cloud, CI/CD y despliegue en producción



 Criterio de Completitud	 Validación
Entorno Local	Funcionalidad operativa en desarrollo
Producción	Probada con datos reales
Documentación API	Endpoint registrado en Swagger
Estabilidad	Sin regresiones en módulos previos
Despliegue Cloud	Variables configuradas en Render

Documentos y Diagramas de Diseño




Figura 1
Árbol de Problema Causas y efectos del problema central





Figura 2
Flujo AS-IS Proceso manual actual con puntos de dolor


Documentos y Diagramas de Diseño

Figura 4
Arquitectura TO-BE Bloques
del sistema y comunicación



Documentos y Diagramas de Diseño

Figura 5:
Modelo ER 6 tablas · FK activas
Aislamiento multi-tenant



Documentos y Diagramas de Diseño

Figura 7: Flujo TO-BE
Proceso nuevo con Agentex
de pregunta a respuesta





Figura 6: Casos de Uso
3 actores · 12 casos
SUPER_ADMIN / ADMIN / USER





Arquitectura de Software y Patrones

Microservicios con separación de responsabilidades en 3 capas

 Capa	 Tecnología	 Responsabilidad
 Presentación	React · Vercel	Interfaz web, navegación y estado del chat
 Orquestación	Node.js + Express · Render	Autenticación, lógica de negocio y consultas ERP
 Procesamiento IA	Python + FastAPI · Render	Comunicación con DeepSeek y generación de respuestas

Patrones implementados

 Patrón	 Implementación
 Strategy	Selección dinámica de motores desde base de datos
 Service Layer	Separación entre lógica de negocio y controladores
 Multi-Tenant	Aislamiento por company_id en Supabase
 Proxy	Python como intermediario hacia DeepSeek
 Cache-Aside	Caché temporal por empresa con TTL de 60 segundos



Diagramas C4 Nivel 1 y Nivel 2 → Figuras 10 y 11

Stack Tecnológico Definitivo



Frontend

 Tecnología	 Uso
React 18 + Vite	Desarrollo de interfaz web
JavaScript ES2022	Lógica del cliente
Tailwind CSS	Estilos responsivos
Framer Motion	Animaciones UI
React Router DOM	Navegación SPA
React Markdown	Renderizado Markdown
Lucide React	Iconografía
Vercel	Despliegue frontend

Backend

 Tecnología	 Uso
Node.js 20 + Express 4	API REST principal
JavaScript ES2022	Lógica del servidor
Supabase JS Client	Acceso a base de datos
JWT + Bcrypt	Autenticación y seguridad
Express Rate Limit	Protección anti abuso
Swagger UI + YAML	Documentación API
Pino	Logs estructurados
Render	Despliegue backend

Tip clave: *Tiempo sugerido: 2 min. Mostrar el repositorio abierto en pantalla durante la exposición.*

Stack Tecnológico Definitivo

Microservicio

 Tecnología	 Uso
Python 3.11 + FastAPI	Microservicio IA
Uvicorn (ASGI)	Servidor de ejecución
HTTPX Async	Comunicación HTTP asíncrona
Pydantic	Validación de datos
Python Dotenv	Variables de entorno
Render	Despliegue IA

Estándares y repositorio:

 Estándar	 Implementación
 Nomenclatura	kebab-case en backend · PascalCase en componentes React
 Estrategia Git	main para producción · dev para desarrollo activo
 CI/CD	Deploy automático tras merge a main
 Repositorio	GitHub Repository

Tip clave: *Tiempo sugerido: 2 min. Mostrar el repositorio abierto en pantalla durante la exposición.*

Stack Tecnológico Definitivo

```

  BACKEND-AGENTEX
  > config
  > controllers
    JS admin.controller.js
    JS agent.controller.js
    JS auth.controller.js
    JS chat.controller.js
    JS company.controller.js
    JS sessions.controller.js
    JS users.controller.js
  > middlewares
    JS auth.js
  > node_modules
  > routes
  > services
    JS analytics.service.js
    JS erp-search.service.js
    JS logistics-search.service.js
    JS sales-search.service.js
    JS text-utils.service.js

```

```


  FRONT-AGENTEX-
  > node_modules
  > public
  > src
    > assets
    > components
      > admin
        CompaniesAdmin.jsx
      > auth
        LoginScreen.jsx
        Register.jsx
      > chat
        ChatInterface.jsx
      > dashboard
        Dashboard.jsx
      > history
        SessionDetail.jsx
        SessionHistory.jsx
      > layout
        Sidebar.jsx
    > provisioning
      ERPMappingSection.jsx
    > settings
      AgentsSettings.jsx

```


Configuración de Servidor de Producción

Supabase — Base de Datos

 Configuración	 Detalle
Motor	PostgreSQL administrado
Estructura	6 tablas con FK activas
Inicialización	Script DDL ejecutado
Respaldo	Backups automáticos
Plataforma	Supabase



Configuración de Servidor de Producción



Render — Microservicio Python

⚙ Configuración	📌 Detalle
Runtime	Python 3.11
Build	pip install -r requirements.txt
Start	uvicorn main:app
Variables	DEEPSEEK_API_KEY, INTERNAL_SECRET
Plataforma	Render

WEB SERVICE

motor-ia-Agentex

Python 3

Free

Upgrade your instance →

Service ID: `srv-d7vpr157vvec73dltbkg`

MauriLS / motor-ia-Agentex `main`

<https://motor-ia-agentex.onrender.com>

ⓘ Your free instance will spin down with inactivity, which can delay requests by 50 sec

Filter events 31

✓ Deploy live for `788aa19`: Merge branch 'dev'

May 22, 2026 at 12:21 PM

Environment Variables

Set environment-specific config and secrets (such as API keys), then read those values from your code. [Learn more.](#)

KEY	VALUE
DEEPSEEK_API_KEY	
INTERNAL_SECRET	

Configuración de Servidor de Producción

Render — Backend Node.js

⚙ Configuración	📌 Detalle
Runtime	Node.js 20
Build	npm install
Start	node server.js
Variables	JWT, Supabase, secretos internos y URL Python
Plataforma	Render

WEB SERVICE

backend-AgenteX

NodeFreeUpgrade your instance →

Service ID: srv-d7vp8crtqb8s73fj5b80

MauriLS / backend-AgenteXmainhttps://backend-agentex.onrender.com

Edición Herramientas Ayuda

Your free instance will spin down with inactivity, which can delay requests by 50 seconds

Filter events31

Deploy live for 9b701b8: feat(logging): integrar logs estructurados con pino

May 22, 2026 at 11:18 PM

Environment Variables

Set environment-specific config and secrets (such as API keys), then read those values from your code. Learn more.

KEY	VALUE
DEEPSEEK_API_KEY	
INTERNAL_SECRET	
JWT_SECRET	
NODE_ENV	
PORT	
PYTHON_ENGINE_URL	
SUPABASE_KEY	
SUPABASE_URL	


Configuración de Servidor de Producción



Vercel — Frontend

⚙ Configuración	📌 Detalle
Framework	Vite
Build	npm run build
Output	dist/
Variables	VITE_API_URL
Routing	vercel.json configurado para SPA
Plataforma	Vercel

Production Deployment



Deployment
front-agente-o26zpvkqx-mauriciolillo122-

Domains +
front-agente-x.vercel.app

Status Created
● Ready 2d ago by MauriLS

Source
main
9327d35 fix: rename ApiFech to apiFetc

Environment Variables

Store API keys, tokens, and config securely. [Learn more](#)

Project Shared

All Environments

VITE_API_URL Sensitive

Production

URL de Producción y Acceso a la App

APLICACIÓN EN PRODUCCIÓN

<https://front-agente-x.vercel.app/app>

Credenciales de prueba	Repositorio de código	Paneles cloud abiertos
Usuario: mauriciolillo122@gmail.com Contraseña: 123456 Rol: Super Admin Usuario: mauriciolillo10@gmail.com Contraseña: 123456 Rol: Admin	Acceso: público Rama desplegada: main Backend Node.js: https://github.com/MauriLS/backend-AgenteX Frontend React: https://github.com/MauriLS/Front-AgenteX Microservicio Python: https://github.com/MauriLS/motor-ia-AgenteX	PANELES ABIERTOS Frontend: vercel.com Backend: render.com BD: supabase.com Docs API: /api/docs Logs en vivo disponibles durante la demo

Demo en Vivo · App en Producción

- 1

Acceso y autenticación
Abrir URL pública desde el navegador Iniciar sesión como SUPER_ADMIN Mostrar dashboard con métricas reales
- 2

AGENTE DE BODEGA
Consultar stock de un producto específico Mostrar respuesta con datos reales del ERP Evidenciar protocolo anti-alucinación
- 3

AGENTE ANALÍTICO
Consultar ingresos por período Mostrar tabla Markdown con datos reales LLM auxiliar extrae rango temporal
- 4

AGENTE DE VENTAS
Buscar cliente por nombre Mostrar flujo de desambiguación Perfil completo con historial de compras
- 5

AGENTE DE LOGISTICA
Buscar ordenes de trabajo pendientes por rango de tiempo, o estado.
- 6

PANEL DE ADMINISTRACIÓN
Aprovisionar empresa con mapeo ERP Gestión de agentes e instrucciones Gestión de usuarios por empresa
- 7

VALIDACIÓN DE SEGURIDAD
Intentar acceso sin token → 401 Intentar acceso con rol incorrecto → 403 Mostrar historial reconstruido desde BD

Evidencia de Funcionamiento en la Nube

Lo que respalda que la app no solo se ve, sino que opera correctamente · 2 minutos

Logs en vivo

Logs estructurados con Pino visibles en tiempo real desde Render, indexados por empresa, motor y tiempo de respuesta

Pipeline CI/CD

Deploy automático en Render y Vercel tras cada merge a main con builds validados

Métricas y monitoreo

Servicios Node.js y Python en estado LIVE con uptime y requests monitoreados en Render

Base de datos viva

Persistencia real en Supabase con registros generados durante la demo y 6 tablas activas

Evidencia de Funcionamiento en la Nube

Logs en vivo

```
02:58:07 PM [m8vqc] 📦 Logistics cache hit → 20:https://6a0e26f01736097c36098b0d.mockapi.io/ordenes
02:58:08 PM [m8vqc] 📦 Rango logistica: 2025-03-01 → 2025-03-31
02:58:08 PM [m8vqc] 📦 Logistica → base: 100 | filtradas: 28 | rango: 2025-03-01 → 2025-03-31
02:58:08 PM [m8vqc] 📦 Logistica → modo: crudo | órdenes: 28
02:58:12 PM [m8vqc] {"level":30,"time":1779649092012,"service":"agentex-backend","env":"production","method":"POST","path":"/message 200 5387ms"}
```

Métricas y monitoreo:

WEB SERVICE

backend-AgenteX

NodeFreeUpgrade your instance →

Service ID: srv-d7vp8crtqb8s73f5b80

MauriLS / backend-AgenteX main

https://backend-agentex.onrender.com

🔍 Filter events 31

Deploy live for 9b701b8: feat(logging): integrar logs estructurados con pino

May 22, 2026 at 11:18 PM

WEB SERVICE

motor-ia-AgenteX

Python 3FreeUpgrade your instance →

Service ID: srv-d7vpr157vvec73dltbkg

MauriLS / motor-ia-AgenteX main

https://motor-ia-agentex.onrender.com

🔍 Filter events 31

Deploy live for 788aa19: Merge branch 'dev'

May 22, 2026 at 12:21 PM

Pipeline CI/CD

```
01:07:57 PM ==> Deploying...
01:07:57 PM ==> Setting WEB_CONCURRENCY=1 by default, based on available CPUs in the instance
01:08:04 PM [cdbxr] ==> Running 'npm start'
01:08:05 PM [cdbxr]
01:08:05 PM [cdbxr] > start
01:08:05 PM [cdbxr] > node server.js
01:08:05 PM [cdbxr]
01:08:06 PM [cdbxr] ◇ injected env (0) from .env // tip: 🔑 secrets for agents [www.dotenvx.com]
01:08:07 PM [cdbxr] ◇ injected env (0) from .env // tip: 🔑 auth for agents [www.vestauth.com]
01:08:07 PM [cdbxr] {"level":30,"time":1779642487688,"service":"agentex-backend","env":"production","port":3000,"env"
01:08:07 PM [cdbxr] {"level":40,"time":1779642487875,"service":"agentex-backend","env":"production","method":"HEAD","pi
01:08:09 PM ==> Your service is live 🎉
01:08:09 PM [cdbxr] {"level":40,"time":1779642489362,"service":"agentex-backend","env":"production","method":"GET","pa
01:08:09 PM ==>
01:08:09 PM ==> ///////////////////////////////////////////////////
01:08:09 PM ==>
01:08:09 PM ==> Available at your primary URL https://backend-agentex.onrender.com
01:08:09 PM ==>
01:08:09 PM ==> ///////////////////////////////////////////////////
```

Base de datos viva

public.messages	public.companies	public.agent_templates	public.company_agents	public.users	
Filter by id, session_chat_id, content... or ask AI					
	id int4	session_chat_id int4	content text	sender_type varchar	prompt_tokens
376	74	→	dame los clientes que mas compran	USER	0
377	74	→	No tengo acceso a datos históricos de ver	IA	1826
378	75	→	Dame los cliente que mas compran	USER	0
379	75	→	No tengo acceso a datos históricos de ver	IA	1825
380	76	→	Dame los clientes que mas compran	USER	0
381	76	→	Hola, soy el Asistente Comercial de Zxtre	IA	1826
382	76	→	dame el cliente leo	USER	0
383	76	→	¡Hola! Claro, aquí tienes la información de	IA	2131
384	77	→	Comparas las ventas del trimestre anterio	USER	0
385	77	→	No tengo datos del trimestre anterior (julio	IA	3547


Matriz de Avance de Funcionalidades

#	FUNCIONALIDAD	DESCRIPCIÓN BREVE	EVIDENCIA	ESTADO
1	Autenticación multi-tenant	Login JWT con roles SUPER_ADMIN / ADMIN / USER	<u>URL</u>	IMPLEMENTADA
2	Motores especializados	4 motores: bodega, analítica, ventas, logística conectados a ERP	URL + PR #__	IMPLEMENTADA
3	Protocolo anti-alucinación	Sistema prompt jerárquico de 5 niveles con datos reales	URL + PR #__	IMPLEMENTADA
4	Aprovisionamiento B2B	Crear empresa + agentes + mapeo ERP desde formulario web	URL + PR #__	IMPLEMENTADA
5	Panel administración por roles	SUPER_ADMIN gestiona empresas · ADMIN gestiona usuarios y agentes	Capturas en anexo	IMPLEMENTADA
6	Motor RAG	Ingesta de documentos privados corporativos.	Pendiente para EA3	EN PROGRESO

Integraciones Necesarias

API DeepSeek

⚙️ Componente	📌 Detalle
Servicio	DeepSeek · SaaS
Modelo	deepseek-chat
Uso	Respuesta final IA y extracción de intención/rangos
Seguridad	API Key almacenada en variables de entorno



Conclusión

PROBLEMA → SOLUCIÓN DEMOSTRADA

La extracción manual de datos corporativos generaba latencia inaceptable en la toma de decisiones de las PyMEs.

AgenteX resuelve esto con 4 motores especializados conectados en tiempo real a los endpoints de cada empresa, con respuestas en lenguaje natural en segundos.

BENEFICIOS DEMOSTRADOS

- ✓ Respuesta en segundos vs horas manual
- ✓ Datos reales · cero alucinaciones
- ✓ Sin curva de aprendizaje técnico
- ✓ Escalable a nuevas empresas en minutos


ESTADO EN PRODUCCIÓN

Funcionalidades implementadas y desplegadas en la URL pública.

96% del MVP operativo y demostrado en vivo.


Anexos · Material de Respaldo

Figura 1
Árbol de problema
Alta resolución



Anexos • Material de Respaldo


Figuras 3.1 - 3.4
Carta Gantt completa
4 sprints • 12 semanas



Anexos · Material de Respaldo



Figura 5 Modelo ER
dbdiagram.io



Anexos • Material de Respaldo






Figura 6 Modelo Actual base de datos





Anexos · Material de Respaldo

Figuras 8 y 9 C4 Nivel



Anexos · Material de Respaldo

Figuras 19 - 26
Capturas del sistema
en producción



Anexos · Material de Respaldo



Swagger API Docs 20
rutas documentadas
/api/docs

AgenteX API

1.0.0OAS 3.0

API multi-tenant para orquestación de agentes IA conectados a ERPs empresariales.

Autenticación

Todas las rutas excepto `/auth/login` y `/auth/register` requieren un Bearer token JWT. Incluye el token en el header: `Authorization: Bearer <token>`

Roles

- `USER` — acceso a chat y datos propios
- `ADMIN` — gestión de empresa, agentes y usuarios de su tenant
- `SUPER_ADMIN` — gestión de todas las empresas

Servers

http://localhost:3000 - Desarrollo local

Authorize

Sistema

GET

/health

Health check

Autenticación

POST

/api/auth/login

Iniciar sesión

POST

/api/auth/register

Registrar nueva empresa (ADMIN)

Chat

POST

/api/chat/message

Enviar mensaje al agente IA

Agentes

Anexos · Material de Respaldo



Swagger API Docs 20
rutas documentadas
/api/docs

AgenteX API

1.0.0OAS 3.0

API multi-tenant para orquestación de agentes IA conectados a ERPs empresariales.

Autenticación

Todas las rutas excepto `/auth/login` y `/auth/register` requieren un Bearer token JWT. Incluye el token en el header: `Authorization: Bearer <token>`

Roles

- `USER` — acceso a chat y datos propios
- `ADMIN` — gestión de empresa, agentes y usuarios de su tenant
- `SUPER_ADMIN` — gestión de todas las empresas

Servers

http://localhost:3000 - Desarrollo local

Authorize

Sistema

GET

/health

Health check

Autenticación

POST

/api/auth/login

Iniciar sesión

POST

/api/auth/register

Registrar nueva empresa (ADMIN)

Chat

POST

/api/chat/message

Enviar mensaje al agente IA

Agentes