

AGENTE X

Integrante del grupo

- Mauricio Lillo

Índice

Índice	2
Introducción	4
Contexto del proyecto	5
Antecedentes, motivación y origen del problema	5
Público objetivo general	5
Estado del arte y formas actuales de resolución	5
Descripción del problema u oportunidad	8
Definición del problema central	8
Descripción del impacto y alcance:	8
Análisis de Causas y Efectos:	8
Descripción del mercado objetivo	10
Definición del usuario y cliente	10
Necesidades principales:	10
Descripción de dolores:	10
Escenario de uso:	10
Perfiles de Usuario	11
Objetivo general y objetivos específicos	12
Objetivo General	12
Objetivos Específicos	12
Situación inicial del cliente (AS-IS)	14
Análisis del flujo operativo actual	14
Identificación de Puntos de Dolor (Pain Points)	14
Planificación	16
Distribución de Tareas por Sprint	16
Backlog de Historias de Usuario	17
Servicios Cloud a utilizar (IaaS / PaaS / SaaS)	19
Arquitectura de Despliegue en el VPS	19
Conceptualización	21
9.1 Descripción de la solución	21
9.2 Funcionalidades principales	21
9.3 Entregables	22
9.4 Consideraciones de calidad y seguridad	22
9.5 Diagrama de Arquitectura de la Solución	23
Alcance, supuestos y restricciones	24
Alcance del Proyecto	24
No Alcance	24
Entregables	25
Supuestos	25

Restricciones	25
Conclusión	26
Resumen del problema y la solución propuesta	26
Beneficios esperados	26
Próximos pasos en el semestre	26
Anexos	28

Introducción

La gestión de la información en el entorno empresarial contemporáneo presenta una paradoja crítica: las organizaciones generan más datos que nunca, pero sus líderes tardan demasiado tiempo en extraer valor estratégico de ellos. En la actualidad, cuando un dueño de negocio o ejecutivo necesita tomar una decisión operativa, se enfrenta a silos de información fragmentados entre reportes financieros estáticos, documentos internos y sistemas de gestión complejos. La extracción de respuestas concretas requiere navegar por paneles de analítica poco intuitivos o depender de intermediarios técnicos, lo que genera un costo de oportunidad altísimo y una latencia inaceptable. Esta fricción administrativa y la alta carga cognitiva que implica cruzar datos manualmente es la situación fundamental que motivó el presente proyecto.

Para resolver este cuello de botella y capitalizar esta oportunidad, se construirá una plataforma web de Inteligencia de Negocios Conversacional (Conversational BI) fundamentada en una arquitectura de Agentes de Inteligencia Artificial. En lugar de obligar al usuario a interpretar gráficos crudos, el sistema actuará como un intermediario cognitivo ágil. A través de la inyección de contexto documental privado y la conexión a fuentes de datos dinámicas de la empresa, la plataforma permitirá a los directivos interactuar en lenguaje natural con agentes virtuales especializados. Estos agentes serán capaces de comprender el contexto del negocio y entregar resúmenes ejecutivos precisos en segundos, eliminando la curva de aprendizaje de las herramientas tradicionales y mitigando el riesgo de alucinaciones genéricas de la IA.

En las siguientes páginas, el lector encontrará un desglose estructurado y estratégico de esta solución. Inicialmente, se detallará el contexto del proyecto y una radiografía profunda del problema, identificando sus causas y el impacto directo en el mercado objetivo. Posteriormente, se definirán los objetivos generales y específicos que guiarán el desarrollo, seguidos de un análisis de la situación actual del cliente (AS-IS). Finalmente, el documento expondrá la planificación metodológica, la justificación de los servicios Cloud seleccionados, y la conceptualización de la arquitectura propuesta, delimitando claramente el alcance, los supuestos y las restricciones de este sistema.

Contexto del proyecto

Antecedentes, motivación y origen del problema

En el ecosistema empresarial actual, la velocidad en la toma de decisiones define la supervivencia de una compañía. Sin embargo, existe una desconexión crítica entre la cantidad de datos que genera una empresa y la capacidad de su directiva para consumirlos de forma ágil. La motivación de este proyecto surge de la observación directa y la experiencia empírica en la gestión operativa de negocios de retail, e-commerce y servicios. Se detectó recurrentemente que los dueños de negocios y gerentes invierten una cantidad desproporcionada de tiempo intentando extraer métricas específicas (ej. ventas trimestrales, rotación de inventario) cruzando manualmente hojas de cálculo, leyendo reportes en PDF o navegando por sistemas ERP/CRM complejos.

Hoy en día, la información estratégica está secuestrada detrás de interfaces técnicas. Cuando un directivo necesita una respuesta rápida antes de una reunión, el flujo actual lo obliga a solicitar un reporte a un analista o a buscarlo él mismo, generando latencia operativa. Esta fricción hace que la toma de decisiones se vuelva reactiva en lugar de proactiva.

Público objetivo general

El usuario principal de esta solución está compuesto por dueños de negocios (PyMEs y medianas empresas), ejecutivos C-Level (CEOs, CFOs) y gerentes operativos que requieren inmediatez en el acceso a la información. Son perfiles con un alto costo de oportunidad, que no desean invertir tiempo en interpretar gráficos densos, sino que buscan respuestas sintetizadas y exactas. Secundariamente, la arquitectura del sistema es escalable hacia el sector educativo (EdTech) e institucional, donde entidades universitarias pueden desplegar "agentes-profesores" para que los estudiantes consulten bibliografía masiva con la misma lógica de lenguaje natural.

Estado del arte y formas actuales de resolución

Actualmente, el mercado intenta resolver esta necesidad mediante dos extremos que no logran conectarse. Por un lado, se utilizan herramientas de *Business Intelligence* (BI) tradicionales como PowerBI o Tableau, las cuales son potentes visualmente, pero requieren conocimientos técnicos para su configuración y no responden a consultas conversacionales de forma nativa. Por otro lado, la irrupción de modelos de lenguaje genéricos (como ChatGPT o Claude) ha democratizado la Inteligencia Artificial, pero estas herramientas carecen de conocimiento sobre la

realidad interna y privada de la empresa, lo que las lleva a generar respuestas imprecisas o a inventar datos (alucinaciones) si no se les inyecta el contexto adecuado.

Esta desconexión demuestra que las soluciones actuales no bastan. Resolver el problema integrando manualmente PDFs en un chat público es inseguro para los datos empresariales y poco escalable. Se requiere una plataforma puente que fusione la agilidad del chat con la rigurosidad de los datos corporativos privados.

Solución / Competidor	¿Qué hace?	Ventaja	Desventaja	¿Qué haré distinto?
 Herramientas de BI Tradicional (PowerBI, Tableau)	Extrae datos de bases de datos y los convierte en paneles de control y gráficos interactivos.	Altísima precisión en los datos. Visualización profunda y capacidades matemáticas avanzadas.	Curva de aprendizaje empinada. Interfaces rígidas. No responde al lenguaje natural de forma conversacional rápida.	Interfaz Conversacional: Reemplazar los gráficos complejos por respuestas directas y sintetizadas en texto mediante IA, ahorrando la fase de interpretación visual al usuario.
 LLMs Genéricos y Públicos (ChatGPT, Claude, Gemini)	Asistentes de IA basados en la nube que responden preguntas, redactan y analizan textos subidos manualmente.	Flexibilidad total, lenguaje natural extremadamente avanzado, fácil uso.	Riesgo crítico de alucinaciones. Desconocen los datos privados de la empresa. No se conectan a endpoints o bases de datos en tiempo real.	Contexto Estricto (RAG) y Endpoints: La IA estará restringida a responder basándose únicamente en los documentos corporativos cargados y en los datos extraídos de las APIs de la empresa, garantizando respuestas reales y actualizadas.

 Chatbots de ERPs Corporativos (SAP, CoPilot)	Asistentes virtuales integrados nativamente dentro de software de gestión empresarial de gran escala.	Conexión directa con la base de datos de la corporación. Alta seguridad.	Costos de licencia prohibitivos para PyMEs. Ecosistema cerrado (solo funcionan con su propio software).	Modularidad y Agnosticismo: Crear un sistema independiente y de bajo costo que pueda ingerir cualquier documento y consumir cualquier endpoint mediante APIs, democratizando el acceso a PyMEs.

Descripción del problema u oportunidad

Definición del problema central

Actualmente la extracción manual y visual de métricas desde silos de información corporativa y sistemas de gestión tradicionales exige una alta carga cognitiva a los directivos, lo que provoca una latencia inaceptable en la toma de decisiones estratégicas y un profundo desperdicio del capital de datos de la empresa.

Descripción del impacto y alcance:

El impacto de esta fricción operativa se mide directamente en costos de oportunidad y tiempo. En un entorno corporativo o PyME, el dueño del negocio o ejecutivo pierde horas semanales cruzando datos entre facturación, inventario y reportes en PDF para obtener respuestas simples (ej. "¿Cuál fue la línea de productos más rentable el trimestre pasado considerando el costo de almacenamiento?"). Esta ineficiencia administrativa genera pérdidas financieras ocultas: se pagan horas de recursos humanos altamente calificados (o el tiempo del propio CEO) para realizar tareas de recopilación de datos, en lugar de utilizarlos en la ejecución comercial.

Adicionalmente, genera una mala experiencia para el directivo, quien sufre de fatiga por exceso de información (information overload), viéndose obligado a interpretar paneles visuales genéricos en lugar de recibir conclusiones ejecutivas.

Análisis de Causas y Efectos:

Para entender la anatomía de este fallo operativo, se ha estructurado un análisis basado en el modelo de Árbol de Problemas, desglosando las raíces técnicas que originan el problema y las consecuencias que impactan al negocio.

[En la figura 1 Árbol de problema/oportunidad](#), podemos ver representada sus causas y efectos.

Las Causas:

1. **Silos de datos desconectados y estáticos:** La información de la empresa vive en formatos incompatibles. Los reportes cualitativos están en PDFs aislados, mientras que los datos cuantitativos viven en bases de datos (ERPs/CRMs) que requieren consultas SQL complejas o navegación manual.
2. **Fricción en la Interfaz de Usuario (UI):** Los sistemas actuales dependen de *dashboards* (paneles de control) que exigen al usuario aprender a filtrar, cruzar y exportar información. No están diseñados para consultas naturales, directas y conversacionales.

3. **Limitaciones de la IA Pública:** Los modelos de lenguaje grandes (LLMs) genéricos carecen de acceso a la intranet, los documentos privados o las bases de datos de la empresa. Si un usuario intenta usarlos sin un sistema de inyección de contexto, la IA "alucina" inventando datos, volviéndola inútil para la toma de decisiones críticas.

Los Efectos:

1. **Toma de decisiones reactiva y demorada:** Al carecer de respuestas en tiempo real, las decisiones se toman basadas en intuición o con días de retraso, perdiendo agilidad competitiva.
2. **Subutilización del capital de datos:** Gran parte del conocimiento documentado de la empresa (manuales, historiales, normativas) se convierte en "datos muertos" porque el costo en tiempo para leerlos y encontrarlos es superior al beneficio.
3. **Sobrecarga administrativa y dependencia técnica:** El dueño del negocio depende de analistas o personal de TI para generar reportes ad-hoc, creando un cuello de botella en los flujos de trabajo de la directiva.

Descripción del mercado objetivo

Definición del usuario y cliente

El mercado objetivo de esta plataforma opera bajo un modelo B2B. El cliente principal es quien toma la decisión de compra y autoriza la integración del sistema es el dueño del negocio, el CEO o el Director de Operaciones de una PyME o empresa mediana. Sin embargo, el usuario final quien utilizará la plataforma todos los días se divide en dos capas: la alta dirección para consultas estratégicas, y los gerentes de las áreas de Ventas, Logística, Finanzas para consultas tácticas y operativas.

Necesidades principales:

El usuario necesita lograr una sola cosa en el menor tiempo posible: **certeza operativa**. Necesita resolver la fricción entre la pregunta de negocio que tiene en la cabeza y el dato duro que vive en la base de datos de la empresa. Específicamente, necesita centralizar la consulta de información, eliminar la dependencia de terceros como analistas de datos o soporte de TI, para obtener reportes diarios, y sintetizar documentos densos en directrices accionables en cuestión de segundos, interactuando de forma conversacional.

Descripción de dolores:

Lo que más le molesta al usuario del proceso actual es la latencia y la sobrecarga cognitiva. Sus dolores principales son:

1. **La interfaz técnica:** Odia tener que abrir un software ERP complejo, recordar cómo aplicar filtros específicos y exportar archivos a Excel solo para saber cuánto se vendió ayer.
2. **La fragmentación:** Le frustra que el contexto cualitativo como un contrato en PDF, un manual de producto y el dato cuantitativo como el stock actual vivan en plataformas separadas.
3. **El cuello de botella de reportes:** Sufre al tener que esperar horas o días para que su equipo procese la información y le entregue un resumen ejecutivo antes de una toma de decisión urgente.

Escenario de uso:

La plataforma será utilizada en escenarios de alta presión o transiciones operativas. Un escenario típico es minutos antes de una reunión de directorio: el CEO abre la aplicación web desde su *smartphone* o *laptop*, selecciona al "Agente Financiero" y le

pregunta mediante texto: "*¿Cuál fue el margen de ganancia neto de la línea de repuestos en el Q3 y qué porcentaje representa del total?*". La IA procesa la consulta contra el *endpoint* de ventas, cruza la información con el documento de costos subido previamente, y devuelve un párrafo exacto y justificado en menos de 5 segundos.

Perfiles de Usuario

- **Usuario 1 (Principal): Dueño / Director de E-commerce y Retail.**
 - **Características:** Ejecutivo de 30 a 50 años, dirige una empresa con inventario físico complejo. Su día a día es acelerado, gestiona proveedores, logística y ventas multicanal. No tiene tiempo para aprender a usar software de analítica avanzado.
 - **Necesidad:** Requiere consultar el nivel de stock crítico, cruzarlo con el volumen de ventas semanal y entender qué productos están estancados en bodega, todo a través de una simple pregunta en su teléfono para poder tomar decisiones rápidas de re-abastecimiento o campañas de marketing.
- **Usuario 2 (Secundario): Director Académico.**
 - **Características:** Profesional inmerso en un entorno universitario o de capacitación corporativa. Maneja volúmenes masivos de bibliografía, regulaciones o mallas curriculares densas.
 - **Necesidad:** Necesita un "profesor virtual" que haya ingerido (vía RAG) todos los documentos oficiales de una materia o institución. Su objetivo es hacer consultas técnicas precisas sobre la materia y que el agente le responda indicando exactamente en qué página del PDF o manual se encuentra la justificación teórica, ahorrando horas de lectura investigativa.

Objetivo general y objetivos específicos

Objetivo General

Desarrollar una plataforma web de Inteligencia de Negocios Conversacional, basada en una arquitectura de Agentes de Inteligencia Artificial, que permita a dueños de negocios y ejecutivos extraer, centralizar y sintetizar información estratégica en tiempo real, mediante la inyección de contexto documental privado (RAG) y la consulta de *endpoints* dinámicos, reduciendo la latencia en la toma de decisiones operativas.

Objetivos Específicos

Para garantizar el cumplimiento del objetivo general, el desarrollo del sistema se desglosa en los siguientes objetivos técnicos, medibles y trazables:

1. **Diseñar e implementar una arquitectura de persistencia relacional** estricta que gestione la integridad referencial entre los perfiles de usuario, el catálogo de agentes de IA y los permisos de acceso a documentos de contexto, asegurando que cada sesión de chat mantenga un registro inmutable para su posterior auditoría.
 - *Métrica de validación:* Despliegue de la base de datos con llaves foráneas activas y cero orfandad de datos en las pruebas de estrés de las entidades pivote.
2. **Desarrollar un módulo de ingesta y gestión de contexto** que permita la carga segura de archivos privados de la empresa y su vinculación lógica a agentes específicos, mitigando el riesgo de alucinaciones del Modelo de Lenguaje Grande (LLM).
 - *Métrica de validación:* Comprobación empírica de que el agente responde exclusivamente basándose en el texto del documento asignado, devolviendo errores controlados ante preguntas fuera de su alcance.
3. **Integrar la capacidad de consumo de *endpoints* dinámicos** en el flujo de decisión del agente de IA, dotando al sistema de la habilidad para consultar bases de datos externas (ej. niveles de inventario, ventas recientes) en tiempo real durante la conversación.
 - *Métrica de validación:* Ejecución exitosa de peticiones HTTP (GET/POST) gatilladas autónomamente por el agente en base a la intención del usuario.
4. **Construir una interfaz de usuario (UI) web reactiva y asíncrona** que facilite la interacción en lenguaje natural con los agentes, implementando un flujo de estados de procesamiento en tiempo real para mantener al usuario

informado sobre las fases de consulta de la IA (preparación de contexto, consulta al motor, generación de respuesta).

- *Métrica de validación:* Actualización de la interfaz del chat sin recarga de página mediante el manejo eficiente del *Event Loop* y flujos asíncronos en el cliente.

Situación inicial del cliente (AS-IS)

Análisis del flujo operativo actual

El proceso actual de extracción de inteligencia de negocios y consulta de información en una PyME, e-commerce o departamento corporativo es manual, fragmentado y altamente dependiente de la intervención humana. La arquitectura de información del cliente (AS-IS) opera bajo un modelo de "silos desconectados", donde el contexto cualitativo (manuales, contratos, PDFs) y los datos cuantitativos (inventario, ventas, bases de datos) no se comunican entre sí.

A continuación, se detalla el proceso paso a paso utilizando la estructura de fricción actual

1. **El usuario hace una solicitud estratégica:** El flujo inicia cuando el director o dueño de la empresa se enfrenta a una decisión crítica y formula una pregunta de negocio compleja. Por ejemplo: *"¿Por qué cayeron las ventas de la línea de movilidad eléctrica y tenemos suficiente stock en bodega para reactivarlo con una campaña de marketing hoy?"*.
2. **Luego el encargado (o el mismo directivo) inicia la recolección manual:** Para obtener la respuesta, debe acceder a múltiples plataformas de forma independiente. Abre el sistema de gestión (ERP) para revisar el inventario actual, entra a la pasarela de pagos o al CRM para descargar las métricas de ventas, y paralelamente debe buscar en sus carpetas locales un archivo PDF con las políticas del proveedor o las especificaciones técnicas de los productos para tener el contexto completo.
3. **Se registra en herramientas intermedias:** La información extraída de los *endpoints* estáticos se exporta en archivos CSV y se registra en una hoja de cálculo unificada (Excel) o se intenta volcar en un panel visual (Dashboard). El usuario o analista debe aplicar fórmulas, limpiar los datos incompatibles y redactar un reporte que cruce los números con lo que leyó en el PDF.
4. **El problema ocurre cuando el tiempo de respuesta anula la oportunidad de negocio:** Los puntos de dolor críticos se generan en la fase de cruce manual. El problema estalla cuando el directivo necesita esta respuesta en 5 minutos antes de una reunión con inversores o para pausar una campaña publicitaria que está perdiendo dinero, pero el proceso de recolección y síntesis de datos tarda horas o incluso días.

Identificación de Puntos de Dolor (Pain Points)

- **Cuello de botella humano (Latencia):** El proceso depende de la velocidad a la que un humano pueda leer, descargar y cruzar datos.

- **Ceguera de contexto:** Los sistemas de inventario o ventas muestran "qué" pasó (cayeron las ventas), pero no "por qué" pasó (la respuesta cualitativa suele estar escondida en documentos estáticos que el ERP no lee).
- **Fatiga de decisión:** El directivo invierte su energía cognitiva intentando entender de dónde salió el dato.

A continuación se presenta el análisis de la situación actual del cliente en la figura 2.




Figura 2: Diagrama de Flujo del Proceso Actual

Fuente: Elaboración propia.

Planificación

La ejecución del proyecto se estructura en un ciclo extendido de 12 semanas, dividido en 4 Sprints de 3 semanas cada uno. Esta holgura temporal está diseñada para mitigar los riesgos de integración asíncrona entre los microservicios (Node.js y Python) y asegurar que el modelo RAG sea sometido a pruebas exhaustivas de latencia y alucinación antes de su entrega.

Como se detalla en las figuras 3.1, 3.2, 3.3 y 3.4.

Distribución de Tareas por Sprint

- **Sprint 1: Cimientos y Gestión de Información (Semanas 1-3 / Figura 3.1)**
 - **HU1 - Arquitectura de Datos:** Despliegue de la base de datos relacional y configuración de la integridad referencial. (*Mayor tiempo asignado para pruebas de orfandad de datos*).
 - **HU2 - Ingesta de Contexto:** Desarrollo del módulo de subida, almacenamiento seguro y procesamiento inicial de documentos corporativos.
- **Sprint 2: Lógica de Negocio y Simulación (Semanas 4-6 / Figura 3.2)**
 - **HU3 - Segregación de Roles:** Vinculación lógica entre agentes, roles y permisos de lectura de documentos.
 - **HU5 - Implementación de Mocking:** Creación del simulador de IA en Node.js para validar la persistencia transaccional sin depender de APIs externas.
 - **HU4 (Fase I) - Interfaz Base:** Diseño arquitectónico y prototipado del chat conversacional frontend.
- **Sprint 3: Desarrollo Core e Integración RAG (Semanas 7-9 / Figura 3.3)**
 - **HU4 (Fase II) - Refinamiento UI:** Finalización de la interfaz reactiva del chat.
 - **HU6 - Estados Asíncronos:** Implementación de Server-Sent Events (SSE) o WebSockets para mostrar el progreso del agente ("Consultando base de datos...").
 - **HU8 - Integración IA Real:** Conexión definitiva del backend con el intermediario Python y la API de DeepSeek utilizando el contexto inyectado.
 - **HU7 - Persistencia de Historial:** Lógica de recuperación de conversaciones previas desde MySQL.
- **Sprint 4: Integración Avanzada y Cierre (Semanas 10-12 / Figura 3.4)**
 - **HU9 - Consumo de Endpoints Vivos:** Habilidadación de la capacidad de la IA para ejecutar *fetches* a bases de datos operativas de la empresa.
 - **HU10 - Resiliencia y Pruebas:** Manejo de caídas, *timeouts* de la API y pruebas de estrés del flujo completo.

- **Cierre Académico:** Consolidación de manuales, documentación técnica final y preparación de la defensa.

Backlog de Historias de Usuario

1. HU1 - Arquitectura de Datos

- **Detalle:** Como administrador del sistema, quiero desplegar la base de datos relacional con integridad referencial estricta, para asegurar que las sesiones de chat entre ejecutivos y agentes no generen datos huérfanos.
- **Resumen técnico:** Creación de las tablas en MySQL y sus llaves foráneas para proteger el historial transaccional.

2. HU2 - Ingesta de Contexto

- **Detalle:** Como dueño de negocio, quiero poder subir documentos privados (PDFs, manuales) a la plataforma, para centralizar la información cualitativa que la IA utilizará como base de conocimiento.
- **Resumen técnico:** Desarrollo del módulo para subir, leer y guardar archivos físicos en el servidor (RAG).

3. HU3 - Segregación de Roles

- **Detalle:** Como administrador del sistema, quiero vincular documentos específicos a perfiles de agentes individuales, para garantizar que un agente de ventas no tenga acceso a los documentos financieros privados (segregación de contexto).
- **Resumen técnico:** Programación de la lógica relacional para restringir qué documentos puede leer cada agente de IA.

4. HU4 - Interfaz Conversacional

- **Detalle:** Como ejecutivo comercial, quiero interactuar con una interfaz de chat web intuitiva, para formular preguntas de negocio en lenguaje natural sin tener que navegar por *dashboards* complejos.
- **Resumen técnico:** Diseño y maquetación del *frontend* del chat para la interacción con el usuario.

5. HU5 - Simulación de IA (Mocking)

- **Detalle:** Como desarrollador, quiero implementar un simulador de respuestas en el backend (Node.js), para validar el guardado de mensajes en la base de

datos de forma independiente, aislando el riesgo antes de conectar el servidor de Python.

- **Resumen técnico:** Creación de respuestas falsas controladas en Node.js para probar la inserción de datos en MySQL.

6. HU6 - Estados Asíncronos

- **Detalle:** Como dueño de negocio, quiero ver en mi pantalla los estados de procesamiento en tiempo real para tener certeza de que el sistema está trabajando en mi solicitud y evitar cierres prematuros de sesión.
- **Resumen técnico:** Implementación de *Server-Sent Events* (SSE) para enviar actualizaciones de estado al *frontend* mientras la IA procesa.

7. HU7 - Persistencia de Historial

- **Detalle:** Como ejecutivo comercial, quiero que mis conversaciones pasadas queden guardadas en el sistema, para poder retomar análisis estratégicos de días anteriores sin tener que repetir el contexto a la IA.
- **Resumen técnico:** Creación de los *endpoints* GET para recuperar y renderizar chats antiguos desde la base de datos.

8. HU8 - Integración Real con IA

- **Detalle:** Como dueño de negocio, quiero que mi pregunta sea procesada por el modelo de IA real utilizando mis documentos cargados, para obtener respuestas exactas que eliminen las alucinaciones de la IA pública.
- **Resumen técnico:** Conexión final mediante HTTP POST entre Node.js, el servidor Python y la API de DeepSeek.

9. HU9 - Consumo de Endpoints

- **Detalle:** Como directivo, quiero que el agente de IA sea capaz de consultar de forma autónoma bases de datos vivas (Endpoints del ERP/CRM), para obtener métricas operativas actualizadas al segundo dentro de la misma conversación.
- **Resumen técnico:** Programación de *Function Calling* para que la IA sepa cuándo y cómo ejecutar llamadas a APIs externas.

10. HU10 - Resiliencia y Fallos

- **Detalle:** Como ejecutivo, quiero recibir un mensaje de contingencia claro si el proveedor de Inteligencia Artificial falla o excede el tiempo límite de espera, para no paralizar mi flujo de trabajo ante caídas de servidores externos.

Servicios Cloud a utilizar (IaaS / PaaS / SaaS)

Justificación Estratégica del Modelo IaaS (VPS) Para el despliegue de la plataforma de Inteligencia de Negocios Conversacional, se descartará el uso de plataformas PaaS de alto nivel (como Vercel o AWS Elastic Beanstalk) a favor de una arquitectura basada en Infraestructura como Servicio (IaaS) mediante un Servidor Privado Virtual (VPS). Esta decisión se fundamenta en tres ventajas competitivas para el mercado B2B:

1. **Control Absoluto y Privacidad:** Al contar con acceso *root* al servidor, se configuran las reglas de red (Firewalls) de forma estricta, garantizando que el entorno donde se procesan los documentos privados de las empresas (RAG) no comparta recursos lógicos con aplicaciones de terceros, evitando el *Vendor Lock-in* de ecosistemas cerrados.
2. **Eficiencia de Costos (OPEX):** Un VPS ofrece recursos dedicados (vCPU y RAM) a un costo fijo mensual muy inferior al de microservicios facturados por consumo de tiempo de cómputo, lo cual es ideal para la fase de validación (MVP) de modelos de IA.
3. **Despliegue Monolítico Modular:** Permite alojar el frontend, backend y base de datos en una misma máquina virtual, reduciendo la latencia de red a cero entre los servicios (comunicación interna por *localhost*), sin perder la capacidad de separarlos en el futuro.

Arquitectura de Despliegue en el VPS

- **Frontend:**
 - **Tecnología:** Nginx (o Apache) operando nativamente en el VPS.
 - **Justificación:** Nginx actuará como el punto de entrada público, sirviendo los archivos estáticos (HTML/CSS/JS) de la interfaz de usuario y funcionando como Proxy Inverso para enrutar de forma segura las peticiones del chat hacia el puerto interno donde opera Node.js. Además, gestionará los certificados SSL para cifrar el tráfico de extremo a extremo.
- **Backend y API:**
 - **Tecnología:** Node.js gestionado mediante un administrador de procesos (PM2).
 - **Justificación:** El servidor principal de Node.js correrá ininterrumpidamente en el entorno Linux del VPS. PM2 se encargará de monitorear la aplicación, garantizando que si ocurre un error asíncrono o un fallo en el consumo de un *endpoint* de IA, el servidor de

Node.js se reinicie automáticamente sin intervención humana.

- **Base de Datos Relacional:**

- **Tecnología:** MySQL Server instalado localmente en el VPS.
- **Justificación:** Se prescinde de bases de datos como servicio (DBaaS). MySQL operará en el mismo entorno que el backend, lo que asegura que las consultas críticas (como la validación del historial de chat y permisos de agentes) se ejecuten con latencia de red nula, maximizando la velocidad de respuesta del sistema.

- **Autenticación y Almacenamiento de Contexto:**

- **Tecnología:** Autenticación JWT propia (Node.js) y Almacenamiento en Block Storage del VPS.
- **Justificación:** Para mantener la independencia de la plataforma, la validación de usuarios se gestionará internamente, sin depender de Auth0 o Firebase. Paralelamente, los archivos de contexto corporativo, se guardarán directamente en el sistema de archivos (File System) del VPS, asegurando lectura ultrarrápida para el motor RAG de Python sin generar costos adicionales de transferencia de datos en la nube.

Conceptualización

9.1 Descripción de la solución

La solución propuesta consiste en la implementación de un ecosistema de **Inteligencia de Negocios Conversacional** basado en agentes de IA. En este nuevo modelo, el flujo de trabajo se simplifica drásticamente: el directivo deja de ser un recolector de datos para convertirse en un consultor de su propia información.

El sistema operará como una plataforma web donde el usuario interactúa con agentes especializados en lenguaje natural. Cuando el usuario realiza una consulta, el sistema orquesta automáticamente la búsqueda de información en dos vertientes:

- **Contexto Estático:** El motor RAG (*Retrieval-Augmented Generation*) identifica y extrae fragmentos relevantes de los documentos internos (PDFs, manuales, normativas) cargados previamente por la empresa.
- **Contexto Dinámico:** El sistema consume *endpoints* de las APIs corporativas para obtener métricas exactas y actualizadas al segundo (ventas, stock, saldos).

Finalmente, la IA fusiona ambos contextos para entregar una respuesta sintetizada y justificada, eliminando la necesidad de que el usuario interprete gráficos o cruce planillas manualmente.

9.2 Funcionalidades principales

Para cumplir con los objetivos del proyecto, la plataforma integrará las siguientes funcionalidades clave:

1. **Gestión de Agentes Especializados:** Capacidad de configurar múltiples agentes con roles y personalidades distintas (ej. Agente Contable, Agente de Logística), cada uno con acceso restringido a documentos específicos de su área.
2. **Motor de Ingesta Documental RAG:** Módulo para cargar, procesar y vectorizar archivos PDF y de texto, permitiendo que la IA los utilice como base de conocimiento primaria.
3. **Interfaz de Chat Reactiva:** Un entorno de chat asíncrono que permite una comunicación fluida, mostrando al usuario el estado real del procesamiento de su consulta (ej. "Consultando inventario...").
4. **Integración de Endpoints Dinámicos:** Funcionalidad que permite a los agentes ejecutar peticiones HTTP a servicios externos de la empresa para traer datos vivos a la conversación.

5. **Persistencia y Trazabilidad:** Sistema de almacenamiento de historiales de conversación, permitiendo que el usuario retome análisis previos y mantenga la continuidad del contexto de negocio.
6. **Panel de Administración de Contexto:** Interfaz para gestionar qué documentos y qué parámetros de API están activos para cada agente, asegurando el control total sobre la información que maneja la IA.

9.3 Entregables

Al finalizar la etapa de desarrollo, se entregarán los siguientes productos:

- **Plataforma Web Funcional:** Sistema desplegado en un servidor VPS accesible vía navegador, con módulos de login, chat y gestión de documentos operativos.
- **Repositorio de Código Fuente:** Código base en Node.js y Python debidamente documentado en GitHub.
- **Documentación de Arquitectura:** Diagramas de secuencia, entidad-relación y documentación de los contratos de API internos.
- **Manual de Usuario y Configuración:** Guía técnica para que el dueño del negocio pueda cargar sus propios documentos y conectar sus *endpoints*.

9.4 Consideraciones de calidad y seguridad

Dada la sensibilidad de la información empresarial, la solución incorpora los siguientes estándares:

- **Seguridad y autenticación:** Implementación de un sistema de login basado en el cifrado de contraseñas y manejo de sesiones seguras para evitar accesos no autorizados a la información corporativa.
- **Validación de Datos:** Los agentes contarán con reglas de validación para asegurar que la información entregada provenga estrictamente de las fuentes proporcionadas (documentos o APIs), minimizando al máximo el riesgo de alucinaciones.
- **Respaldo y Disponibilidad:** Configuración de respaldos automáticos de la base de datos MySQL en el VPS y monitoreo constante de procesos, para garantizar que el servicio esté disponible cuando el directivo lo requiera.
- **Privacidad de Datos:** Al utilizar un VPS propio e infraestructura controlada, se garantiza que los documentos estratégicos no sean utilizados para el entrenamiento de modelos públicos de terceros.

9.5 Diagrama de Arquitectura de la Solución

A continuación, se representa la estructura lógica de comunicación del sistema. Podemos verla representada en la Figura 4.




Figura 4 - Diagrama de Bloques

Elaboración Propia

Alcance, supuestos y restricciones

Alcance del Proyecto

El desarrollo se delimita a la construcción de un Producto Mínimo Viable (MVP) funcional de una plataforma web de Inteligencia de Negocios Conversacional. Las funcionalidades y características que forman parte estricta de esta entrega son:

- **Módulo de autenticación:** Sistema de inicio de sesión seguro (login) gestionado íntegramente en Node.js mediante JWT y contraseñas encriptadas.
- **Interfaz de Chat Asíncrona:** Entorno web conversacional que permite enviar preguntas en lenguaje natural y visualizar los estados de procesamiento de la IA en tiempo real.
- **Motor de Contexto (RAG):** Capacidad del sistema para ingerir documentos estáticos (texto/PDF) subidos por el usuario, almacenarlos en el servidor y utilizarlos como base de conocimiento para los agentes.
- **Consumo de Endpoints:** Habilitación de la arquitectura para que el servidor intermediario (Python) pueda ejecutar peticiones HTTP GET/POST a APIs externas proporcionadas por el usuario para obtener datos en tiempo real.
- **Persistencia Relacional:** Almacenamiento inmutable del historial de sesiones y mensajes en una base de datos MySQL, garantizando la trazabilidad de las decisiones.

No Alcance

Para garantizar la viabilidad del proyecto en el tiempo estipulado y mantener el enfoque en la arquitectura de Inteligencia Artificial, quedan explícitamente fuera de este desarrollo:

- **Aplicaciones Móviles Nativas:** No se desarrollarán aplicaciones para iOS o Android (App Store / Play Store). El acceso será exclusivamente mediante navegador web responsivo.
- **Interfaces Gráficas 3D o Entornos Virtuales:** Se elimina cualquier componente de "mundos espaciales" o renderizado visual de mapas para los agentes, priorizando la entrega de valor a través de texto puro.
- **Pasarelas de Pago e Integración de Facturación:** El sistema no procesará cobros, suscripciones ni tarjetas de crédito.
- **Conexión directa a Bases de Datos de terceros:** El sistema no se conectará directamente mediante credenciales SQL a los ERPs de los clientes por motivos de seguridad; el cliente debe exponer sus datos mediante URLs (Endpoints/APIs).

Entregables

Al finalizar la doceava semana de desarrollo, se hará entrega formal de:

1. **Producto Software:** Plataforma web desplegada y operativa en un Servidor Privado Virtual (VPS), accesible mediante una URL pública para su evaluación.
2. **Repositorio de Código:** Acceso al código fuente (Node.js, Python, Frontend) alojado en GitHub.
3. **Script de Base de Datos:** Archivo .sql con la estructura relacional (DDL) y llaves foráneas.
4. **Documento de Tesis (Informe Técnico):** El presente documento completo, que detalla la arquitectura, diagramas UML, justificación de negocio y planificación.

Supuestos

El éxito del desarrollo y la implementación del sistema asume que:

- Las empresas usuarias cuentan con su información digitalizada en formatos legibles por máquina (PDFs con texto seleccionable, no imágenes escaneadas de baja resolución) para que el motor RAG pueda vectorizarlos.
- Las empresas que deseen datos en tiempo real poseen APIs RESTful operativas que devuelven respuestas estándar en formato JSON.
- La API del modelo de lenguaje fundacional (DeepSeek) mantiene su disponibilidad y no sufre caídas masivas durante el periodo de evaluación y pruebas.

Restricciones

- **Restricción de Tiempo:** El ciclo de desarrollo está estrictamente limitado a 12 semanas (4 Sprints), lo que obliga a priorizar la estabilidad del núcleo transaccional sobre el diseño estético de la interfaz (UI).
- **Restricciones Tecnológicas (Rate Limits):** La velocidad de respuesta del sistema está condicionada a los límites de peticiones por minuto (*rate limits*) y la latencia inherente del proveedor del modelo de lenguaje externo.
- **Recursos Humanos:** Al tratarse de un proyecto académico unidisciplinario, el 100% del desarrollo *Full-Stack* (Arquitectura, Base de Datos, Backend, Frontend e Integración de IA) recae en un único desarrollador, limitando la paralelización de tareas complejas.

Conclusión

Resumen del problema y la solución propuesta

El presente proyecto nace como respuesta a un cuello de botella crítico en la gestión empresarial moderna: la incapacidad de la alta dirección para extraer valor inmediato de sus propios datos corporativos. Al depender de silos de información estáticos (documentos, PDFs) y sistemas de gestión rígidos (ERPs, Dashboards), las empresas sufren de una latencia operativa que transforma la toma de decisiones en un proceso reactivo. Para resolver esta fricción, se ha propuesto el desarrollo de una plataforma de Inteligencia de Negocios Conversacional (*Conversational BI*). Mediante la implementación de Agentes de Inteligencia Artificial que integran el modelo RAG para la lectura de documentos privados, junto con la capacidad de consumir endpoints en tiempo real, el sistema transforma el lenguaje natural en la única interfaz necesaria para obtener resúmenes ejecutivos exactos, inmediatos y libres de alucinaciones.

Beneficios esperados

La implementación de esta arquitectura entregará tres beneficios fundamentales al mercado objetivo:

1. **Reducción drástica de latencia en la decisión:** Al eliminar la intermediación técnica y la interpretación de gráficos manuales, los directivos obtendrán respuestas estratégicas en segundos, acelerando la capacidad de respuesta del negocio ante fluctuaciones del mercado.
2. **Mitigación del riesgo de alucinaciones (Precisión):** A diferencia de las IAs públicas, el sistema confina el conocimiento del agente estrictamente a los documentos cargados y las bases de datos de la empresa, garantizando que cada respuesta esté fundamentada en la verdad interna del negocio.
3. **Democratización de la Inteligencia de Negocios:** La plataforma elimina la curva de aprendizaje de las herramientas de *Business Intelligence* tradicionales, permitiendo que cualquier usuario, sin importar su nivel técnico, pueda realizar consultas de bases de datos complejas simplemente hablando o escribiendo.

Próximos pasos en el semestre

Con la conceptualización, el alcance y la planificación validados, el proyecto transiciona inmediatamente de la fase de diseño a la fase de ingeniería de software. Durante las próximas semanas del semestre, los pasos a seguir se enfocarán en la ejecución de los Sprints definidos:

- **Despliegue de infraestructura:** Configuración del Servidor Privado Virtual (VPS), instalación de Node.js y estructuración de la base de datos relacional MySQL.
- **Desarrollo del Backend y Mocking:** Programación de las rutas de la API, sistema de autenticación y creación de un simulador de IA local para validar la persistencia de datos.
- **Integración del Motor RAG:** Conexión del backend principal con el servidor intermediario en Python para habilitar la vectorización de documentos y el consumo de la API de DeepSeek.
- **Fase de Pruebas:** Ejecución de pruebas de carga, validación de la interfaz conversacional asíncrona y corrección de latencias antes de la defensa final de la tesis.

Anexos




Figura 1: Árbol de problema/oportunidad

Fuente: Elaboración propia.




Figura 3.1: Planificación Gantt.
Fuente: Elaboración propia.




Figura 3.2: Planificación Gantt.
Fuente: Elaboración propia.




Figura 3.3: Planificación Gantt.

Fuente: Elaboración propia.




Figura 3.4: Planificación Gantt.
Fuente: Elaboración propia.

